

Sistema de Duas Filas com Chegada Única

Bárbara Cássia Florentino Rosa & Beatriz Bastos Assis

Resumo - Este trabalho investiga, por meio de simulação, o desempenho de um sistema de filas paralelas com duas linhas de atendimento, modelado com base nos princípios da teoria de filas. As chegadas seguem um processo de Poisson com taxa λ , e os clientes são alocados dinamicamente à fila com menor número de usuários, aplicando-se um critério de desempate probabilístico em caso de igualdade. Os tempos de serviço obedecem a uma distribuição genérica com média $1/\mu$, permitindo a análise de diferentes perfis de atendimento. A abordagem adotada visa avaliar a eficiência dessa política de roteamento em cenários realistas, considerando variações no tamanho máximo das filas e nas distribuições de serviço. O sistema é comparado com modelos de referência clássicos, como o M/M/2 com alocação aleatória, a fila única com balanceamento automático e o sistema sem espera (com perdas). São analisados indicadores como o tempo médio de espera, a utilização dos servidores e a taxa de perda. Os resultados obtidos contribuem para uma melhor compreensão do impacto das políticas de alocação de clientes sobre o desempenho global de sistemas multi-servidor.

Palavras-Chave—Poisson; Simulação; Sistemas Multi-Servidor; Tempo Médio de Espera; Teoria de Filas.

Abstract - This work investigates, through simulation, the performance of a parallel queueing system with two service lines, modeled based on the principles of Queueing Theory. Arrivals follow a Poisson process with rate λ , and customers are dynamically routed to the queue with the fewest users, applying a probabilistic tie-breaking rule in cases of equal queue lengths. Service times follow a general distribution with mean $1/\mu$, enabling the analysis of different service profiles. The adopted approach aims to evaluate the efficiency of this routing policy under realistic scenarios, considering variations in maximum queue lengths and service time distributions. The system is compared with classical benchmark models, such as the M/M/2 with random allocation, a single shared queue with automatic balancing and a loss system without waiting. Performance metrics such as average waiting time, server utilization, and loss rate are analyzed. The results contribute to a better understanding of how client allocation policies affect the overall performance of multi-server systems.

Keywords—Average Waiting Time; Multi-Server Systems; Poisson; Queueing Theory; Simulation.

I. INTRODUÇÃO

A teoria das filas é um ramo da matemática aplicada dedicado ao estudo do comportamento de sistemas de espera, em que os elementos principais são os clientes (entidades que requerem atendimento) e os servidores (recursos que prestam o serviço). Este campo teórico encontra aplicações em diversas

áreas, como atendimento ao cliente, logística, manufatura e telecomunicações, sendo fundamental para projetar sistemas mais eficientes e com melhor qualidade de serviço. O objetivo central do estudo de filas é determinar e avaliar métricas de desempenho que expressem a produtividade do sistema, além de buscar estratégias para reduzir os impactos negativos das esperas sobre os processos operacionais e a experiência do usuário [1].

No contexto de atendimento ao cliente, como em unidades básicas de saúde, a teoria das filas pode ser empregada para decidir qual fila o paciente deve seguir, considerando a disponibilidade dos profissionais de saúde. Quando um profissional está disponível (isto é, a fila mais curta), o paciente é atendido imediatamente. Em situações em que pacientes apresentam tempos de espera iguais (ressalvando que este modelo não contempla prioridade por gravidade clínica), a escolha aleatória pode ser aplicada para balancear o número de pacientes entre as filas, garantindo uma distribuição equitativa da demanda.

Em eventos como *shows*, parques temáticos ou cinemas, em que os visitantes escolhem filas para entrada ou para serviços como compra de ingressos ou alimentos, modelos com seleção aleatória também podem ser empregados. Estes evitam o acúmulo excessivo em determinadas filas, melhorando a distribuição dos clientes e proporcionando uma experiência mais fluida e satisfatória [2].

Na área de logística, esses modelos se aplicam à gestão de linhas de montagem em indústrias, como a automotiva, por exemplo. Linhas de produção que apresentam carga de trabalho semelhante podem empregar uma distribuição de Bernoulli para direcionar a chegada de novos produtos, equilibrando as tarefas entre as linhas. Essa abordagem contribui para o aumento da eficiência, redução de gargalos e minimização do tempo de inatividade dos recursos.

No setor de telecomunicações, sistemas de filas podem ser utilizados para gerenciar o tráfego em redes de dados móveis ou fixas. Em roteadores ou comutadores, pacotes de dados que chegam precisam ser encaminhados para filas de processamento. O roteador pode direcionar o tráfego para a fila menos carregada ou, em caso de filas igualmente ocupadas, realizar a escolha de forma aleatória com distribuição Bernoulli. Essa estratégia otimiza o uso da largura de banda disponível, reduz a latência de transmissão e permite implementar técnicas de controle de congestionamento, melhorando a qualidade do serviço prestado ao usuário final [3].

Em todos esses cenários, considera-se que os clientes, sejam pessoas, tarefas, pacotes de dados ou produtos, chegam de acordo com um processo de Poisson com taxa λ . Eles buscam a fila com menor comprimento e, quando encontram filas

com o mesmo número de clientes, escolhem aleatoriamente utilizando uma distribuição Bernoulli, sendo atendidos com tempos de serviço que seguem uma distribuição genérica.

Os conceitos de processo de Poisson, distribuição Bernoulli e tempos de serviço serão apresentados nas Seções II e III, juntamente com a modelagem completa do sistema, incluindo variáveis de estado, entidades, eventos e fluxogramas que ilustram os eventos de chegada e de partida. Na Seção IV, são apresentados e discutidos os resultados obtidos. Por fim, na Seção V, são expostas as conclusões com tabelas e gráficos que comparam o desempenho do sistema proposto com outros modelos clássicos de filas.

II. MODELAGEM DO SISTEMA

O sistema modelado consiste em duas filas paralelas associadas a dois servidores idênticos, cada um capaz de atender um cliente por vez, conforme ilustrado na Fig. 1. As chegadas de clientes seguem um processo de Poisson com taxa média constante λ , caracterizando a ocorrência de eventos discretos, independentes e aleatórios em um intervalo de tempo [4]. Este processo é descrito pela distribuição de Poisson, cuja fórmula expressa a probabilidade de ocorrerem exatamente k chegadas em um intervalo [4], [5]:

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad (1)$$

Nesta expressão, $P(X = k)$ é a probabilidade de ocorrência de k eventos, λ é a taxa média de chegadas, e é a base do logaritmo natural e $k!$ representa o fatorial de k .




Figura 1: Ilustração do sistema de duas filas com chegada única. Extraído e reproduzido do enunciado do trabalho.

Ao chegar ao sistema, o cliente observa os comprimentos atuais das filas e seleciona a fila com menor número de clientes. Em situações de empate em que as filas possuem o mesmo comprimento, a escolha é feita aleatoriamente, utilizando a distribuição de Bernoulli com média 0,5, definida pela seguinte fórmula [6]:

$$P(X = k) = p^k (1 - p)^{1-k}, \quad k \in \{0, 1\}, \quad (2)$$

em que p representa a probabilidade de sucesso (por exemplo, de escolher a fila 1), e $1 - p$ a probabilidade de fracasso (neste caso, de escolher a fila 2). No presente modelo, $p = 0,5$, refletindo a equiprobabilidade de escolha entre duas filas iguais.

Os tempos de serviço seguem uma distribuição genérica G com média $1/\mu$, permitindo a análise de diferentes perfis de atendimento além do modelo exponencial tradicional. Essa abordagem amplia a aplicabilidade do modelo para cenários em que os tempos de serviço não seguem a memória sem passado do processo Markoviano.

A capacidade das filas será explorada em cenários com filas finitas (onde clientes podem ser perdidos) e filas de capacidade infinita (onde todos aguardam), possibilitando comparar o desempenho sob diferentes restrições de capacidade [1], [5].

A definição das variáveis de estado, entidades e eventos segue os princípios básicos da modelagem de sistemas de filas [7]:

A. Variáveis de Estado

Em qualquer instante de tempo t , o estado do sistema pode ser descrito pelo par $(Q_1(t), Q_2(t))$, onde $Q_i(t)$ representa o número de clientes na fila i . Além disso, para fins de simulação e análise, são consideradas variáveis complementares:

- Tempo residual de atendimento de cada servidor;
- Disponibilidade de cada servidor (ocupado ou livre);
- Comprimento máximo permitido em cada fila, quando aplicável.

B. Entidades

As principais entidades do modelo são:

- **Cliente:** unidade que chega, aguarda, quando necessário, e recebe atendimento;
- **Servidor:** recurso responsável por processar os clientes;
- **Fila:** estrutura de espera associada a cada servidor.

C. Eventos

Os eventos que alteram o estado do sistema são descritos por um processo de eventos discretos, característico de sistemas de filas Markovianos, em que o futuro do sistema depende apenas do estado atual. São eles:

- **Chegada:** instante em que um novo cliente entra no sistema, iniciando atendimento imediato ou aguardando em fila;
- **Início de Serviço:** ocorre quando o cliente passa do estado de espera para atendimento, caso o servidor esteja livre;
- **Término de Serviço (Partida):** momento em que o cliente conclui o atendimento e deixa o sistema, liberando o servidor;
- **Escolha Aleatória:** evento de decisão acionado em casos de empate entre filas.

A modelagem do sistema, baseada na política *Join the Shortest Queue with Random Tie-Breaking* (JSQ-RTB) [8], ou seja, entrar na fila mais curta com desempate aleatório, visa avaliar como as políticas de roteamento influenciam métricas como tempo médio de espera, taxa de perda e utilização dos servidores. Nas seções seguintes, fluxogramas de eventos e algoritmos utilizados na simulação serão apresentados para melhor detalhar a lógica de evolução do sistema.

III. METODOLOGIA

A análise do sistema proposto foi conduzida por meio de simulação de eventos discretos, implementada em *Python* no ambiente *Colab*, utilizando bibliotecas como *numpy* e *random* para geração de variáveis aleatórias. Essa abordagem permite modelar de forma precisa o comportamento estocástico de chegadas e serviços em sistemas de filas, possibilitando a comparação de diferentes políticas de roteamento e distribuições de serviço [7].

A simulação considera chegadas de clientes segundo um processo de Poisson com taxa λ , geradas pelo método da função inversa para intervalos exponenciais:

$$T_{i+1} = T_i + E_i, \quad \text{em que } E_i \sim \text{Exponencial}(\lambda), \quad (3)$$

em que T_{i+1} é o instante de chegada do próximo cliente.

Os tempos de serviço são amostrados de distribuições especificadas em cada experimento, todas com média $1/\mu$, permitindo avaliar comportamentos com distribuições exponencial, Erlang, log-normal e determinística. Essa modelagem de chegadas e serviços baseia-se em técnicas de geração de variáveis aleatórias [6].

As principais entradas do modelo são:

- Taxa de chegada λ (processo de Poisson);
- Distribuição de tempo de serviço com média $1/\mu$;
- Regra de roteamento em que o cliente seleciona a fila com menor comprimento. Em caso de empate, aplica-se distribuição de Bernoulli com $p = 0, 5$.

As métricas de desempenho (saídas) analisadas incluem:

- Tempo médio de espera na fila (W_q);
- Tempo médio no sistema (fila + serviço) (W_s);
- Comprimento médio de cada fila;
- Utilização de cada servidor (ρ);
- Taxa de perda de clientes (T_{loss}), quando aplicável;
- Taxa de saída do sistema (T_{out});
- Probabilidade de um cliente ter que esperar (P_w);
- Probabilidade de bloqueio (P_b) em cenários com filas finitas.

Para assegurar a validade estatística, a simulação foi realizada em 30 repetições independentes, com período inicial de *warm-up* desprezado na análise dos indicadores. Cada experimento foi executado até atingir um tempo de simulação T_{sim} suficientemente grande para garantir a estabilidade dos resultados, conforme recomendações de análise estatística em simulações de eventos discretos [7], [9].

Tais metodologias foram fundamentadas nos fluxogramas de eventos, que descrevem de forma clara a evolução do sistema a cada chegada e a cada término de serviço. O uso de fluxogramas para descrever processos em sistemas estocásticos segue recomendações de padronização em simulação [9]. As Figuras 2 e 3 ilustram a lógica dos eventos de chegada e partida, respectivamente, construídas com a biblioteca *TikZ*.

O código em *Python* utilizado para a simulação está disponibilizado como anexo, possibilitando a reprodutibilidade dos experimentos e a realização de novos estudos.

IV. RESULTADOS

A simulação foi conduzida com 30 execuções independentes para cada cenário, garantindo robustez estatística na estimação das métricas de desempenho. Foram analisados diferentes valores da taxa de chegada λ e múltiplas distribuições de tempo de serviço (Exponencial, Normal, Uniforme), em quatro modelos de filas: sistema com duas filas paralelas com política JSQ-RTB, fila única (M/G/2), sistema com perda (M/G/2/0) e fila limitada (M/G/2/K) [7], [9].

Os resultados permitem comparar o impacto da distribuição do tempo de serviço, da política de roteamento e da capacidade das filas sobre as métricas de desempenho, sendo possível identificar as condições em que o sistema se aproxima do limite de saturação.

A. Métricas de Desempenho

Para cada replicação, foram coletadas as seguintes métricas [10], [11]:

- Tempo médio de espera na fila (W_q)
- Tempo médio no sistema (W_s)
- Utilização média dos servidores (ρ)
- Tamanho médio das filas (L_q)
- Probabilidade de perda (T_{loss}), quando aplicável.

As médias foram agrupadas por modelo e distribuição, e os intervalos de confiança a 95% foram calculados para cada métrica [7], [9]. O resumo dos resultados é mostrado na Tabela I.

Tabela I: Resumo dos resultados por modelo e distribuição.

Modelo	Distribuição	W_q	W_s	ρ	T_{loss}
JSQ-RTB	Exponencial	0.0038	0.0159	0.06	0.00
JSQ-RTB	Normal	0.0095	0.0173	0.06	0.00
JSQ-RTB	Uniforme	0.0020	0.0155	0.06	0.00
M/G/2	Exponencial	...	...	...	...
M/G/2/0	Exponencial	...	...	...	0.15
M/G/2/K	Normal	...	...	...	0.07

B. Cálculos Teóricos Esperados

Para validação dos resultados simulados, foram calculadas métricas teóricas dos sistemas M/M/1 e M/G/1, considerando as três distribuições de tempo de serviço testadas:

$$W_q = \frac{\lambda E[S^2]}{2(1 - \rho)}, \quad (4)$$

$$W = W_q + E[S], \quad (5)$$

$$L_q = \lambda W_q, \quad (6)$$

$$L = \lambda W, \quad (7)$$

$$p_0 = 1 - \rho, \quad (8)$$

$$P_k = \rho^k (1 - \rho). \quad (9)$$

Essas fórmulas servem como referência para análise da aderência dos resultados simulados aos modelos teóricos clássicos de filas.




Figura 2: Fluxograma do evento de chegada de cliente ao sistema.




Figura 3: Fluxograma do evento de término de serviço (partida) do cliente.

C. Análise Gráfica

As Figuras 4 e 5 ilustram, respectivamente, a variação do tempo médio de espera na fila e da utilização dos servidores em função da taxa de chegada λ . Nota-se que, a partir de $\lambda = 1,5$, o sistema se aproxima rapidamente do limite de saturação, evidenciado pelo crescimento acentuado do tempo de espera.




Figura 4: Tempo médio de espera (W_q) em função da taxa de chegada λ .




Figura 5: Utilização média dos servidores (ρ) em função da taxa de chegada λ .

M/G/2 com alocação aleatória [12]. À medida que a carga aumenta (altos valores de λ), os modelos com filas finitas apresentaram crescimento na taxa de perda, evidenciando a importância de definir corretamente a capacidade das filas para evitar congestionamentos.

A análise evidencia ainda que distribuições com maior variabilidade no tempo de serviço, como a Normal, tendem a aumentar o tempo médio de espera, mesmo sob níveis de ocupação moderados, o que reforça a relevância de modelar corretamente a distribuição do tempo de atendimento em sistemas reais.

D. Discussão dos Resultados

Os resultados mostram que o modelo JSQ-RTB apresenta desempenho superior em cenários de carga moderada, equilibrando a ocupação entre os servidores e reduzindo significativamente o tempo médio de espera em comparação com o

V. CONCLUSÃO

Neste trabalho, foi desenvolvido e analisado um modelo de sistema de filas com duas linhas de atendimento em paralelo, considerando chegadas distribuídas segundo um processo de Poisson, política de roteamento baseada na fila mais curta com desempate aleatório (JSQ-RTB) e tempos de serviço com diferentes distribuições.

Por meio de simulação de eventos discretos, foram obtidas métricas de desempenho que evidenciam o impacto da taxa de chegada, da capacidade das filas e da distribuição de tempo de serviço sobre indicadores como tempo médio de espera, utilização dos servidores e taxa de perda de clientes. Observou-se que a política JSQ-RTB permite balancear a carga entre os servidores, reduzindo o tempo médio de espera em cenários de baixa e moderada carga. Contudo, quando a taxa de chegada λ se aproxima da capacidade do sistema, há crescimento exponencial do tempo de espera e aumento da taxa de perda em filas de capacidade finita.

A análise comparativa com métricas teóricas de modelos M/M/1 e M/G/1 demonstrou boa aderência dos resultados simulados, validando a implementação. A inclusão de distribuições de tempo de serviço mais realistas, como Normal e Uniforme, permitiu observar que a variabilidade no tempo de atendimento impacta significativamente o desempenho do sistema.

Como limitações, destaca-se que a simulação considerou apenas dois servidores e cenários com filas independentes, não explorando interações entre filas ou políticas mais avançadas de priorização. Para trabalhos futuros, recomenda-se estender o modelo para múltiplos servidores com compartilhamento de

filas, análise de diferentes disciplinas de atendimento (FIFO, LIFO, prioridades) e aplicação em contextos específicos como call centers ou redes de telecomunicações, incluindo custos operacionais para otimização do desempenho do sistema.

Os resultados obtidos contribuem para a compreensão do impacto das políticas de roteamento e das características do tempo de serviço no desempenho de sistemas multi-servidor, podendo apoiar decisões de dimensionamento em aplicações reais.

REFERÊNCIAS

- [1] F. S. Hillier and G. J. Lieberman, *Introdução à Pesquisa Operacional*, 9th ed. Porto Alegre: AMGH, 2013.
- [2] M. P. Groover, *Automation, Production Systems, and Computer-Integrated Manufacturing*, 3rd ed. Upper Saddle River, NJ: Pearson Prentice Hall, 2010.
- [3] J. F. Kurose and K. W. Ross, *Computer Networking: A Top-Down Approach*, 7th ed. Boston: Pearson, 2017.
- [4] D. Gross, J. F. Shortle, J. M. Thompson, and C. M. Harris, *Fundamentals of Queueing Theory*, 4th ed. Hoboken, NJ: Wiley, 2008.
- [5] L. Kleinrock, *Queueing Systems Volume 1: Theory*. New York: Wiley, 1975.
- [6] S. M. Ross, *Introduction to Probability Models*, 11th ed. Amsterdam: Academic Press, 2014.
- [7] A. M. Law, *Simulation Modeling and Analysis*, 5th ed. New York: McGraw-Hill, 2014.
- [8] W. L. Winston, "Optimality of the shortest line discipline," *Journal of Applied Probability*, vol. 14, no. 1, pp. 181–189, 1977.
- [9] J. B. et al., *Discrete-Event System Simulation*, 5th ed. Prentice Hall, 2010.
- [10] D. Gross and C. M. Harris, *Fundamentals of Queueing Theory*, 3rd ed. Wiley, 1998.
- [11] W. D. Kelton, R. P. Sadowski, and N. B. Zupick, *Simulation with Arena*, 5th ed. New York: McGraw-Hill, 2010.
- [12] W. L. Winston, *Operations Research: Applications and Algorithms*, 4th ed. Duxbury Press, 2004.